MODELOS DE LINGUAGEM E GENERATIVOS

Conceitos Fundamentais, Arquiteturas e Aplicações Práticas

MÓDULO 1

Panorama Geral e Evolução da IA Generativa

Transição da IA analítica tradicional para a síntese multimodal e a centralidade dos dados corporativos.

A IA Generativa Sintetiza Padrões para Criar Conteúdos Multimodais Originais

IA Tradicional (Analítica e Preditiva)

Foco Principal: Classificação, regressão e detecção de padrões estatísticos em dados tabulares ou estruturados.

Mecanismo de Saída: Predição de rótulos ou valores numéricos (ex: score de crédito, filtro de spam, fraude).

Aprendizado Supervisionado: Requer grandes volumes de dados rotulados manualmente para cada tarefa específica.

Limitação: Incapaz de sintetizar novos conteúdos não presentes de forma explícita na entrada.

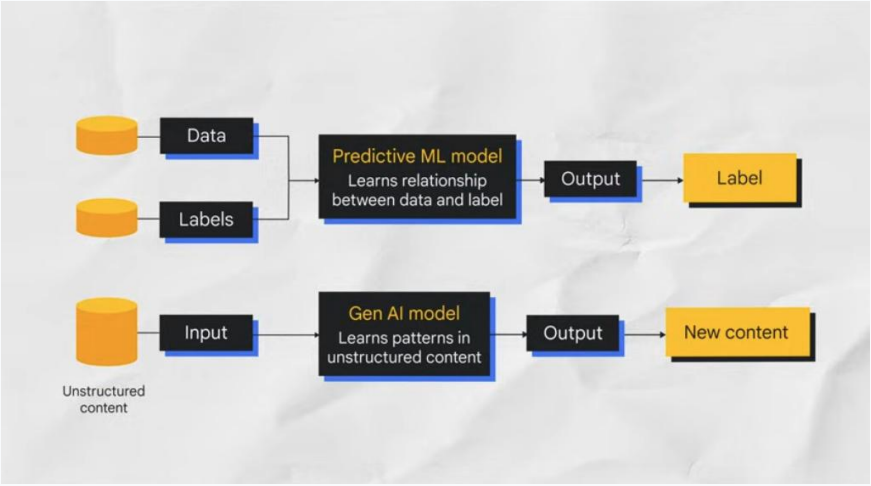
IA Generativa (Sintética e Multimodal)

Foco Principal: Aprender distribuições de probabilidade complexas para gerar dados inéditos e plausíveis.

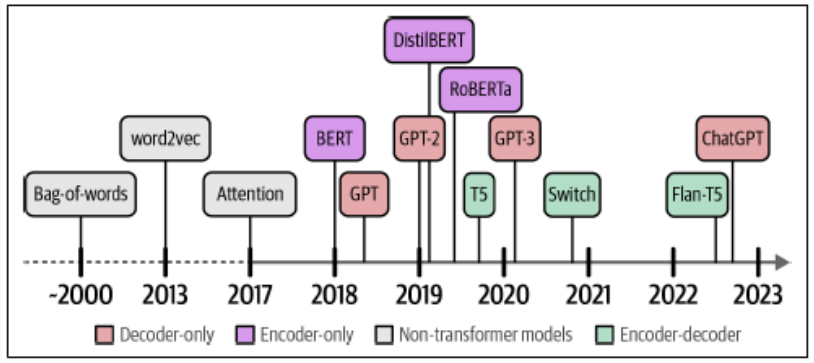
Mecanismo de Saída: Criação de textos, imagens, código computacional, áudio, vídeos e estruturas 3D.

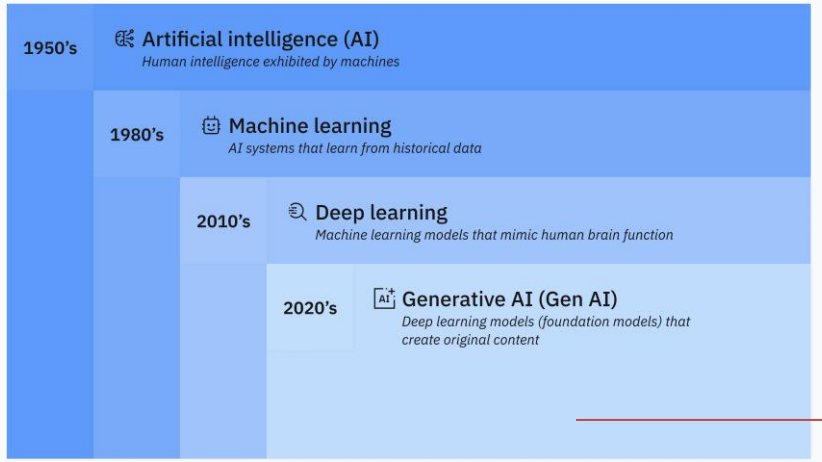
Escala de Parâmetros: Redes neurais profundas treinadas em escala Web (centenas de bilhões de parâmetros).

Impacto Prático: Automatização do trabalho de conhecimento e criação de novas interfaces de interação.



A IA de Linguagem Evoluiu de Representações Estáticas para o Processamento Paralelo via Atenção





Marcos da Evolução (Hands-On LLMs - Cap. 1)

1. **Métodos Estatísticos (Bag-of-Words):** Frequência de palavras sem consideração de ordem ou contexto semântico.

2. **Embeddings Estáticos (Word2Vec, GloVe):** Mapeamento de palavras em vetores, mas com representação única (ex: 'manga' fruta vs vestuário).

3. **Modelos Recorrentes (RNN / LSTM):** Processamento sequencial palavra a palavra; sofriam com esquecimento em textos longos.

4. **Mecanismo de Atenção (2014):** Permitiu focar dinamicamente em partes relevantes da sequência de entrada.

5. **Arquitetura Transformer (2017):** Eliminou a recorrência, viabilizando treinamento massivamente paralelo via GPUs.

Gen AI Como um subset do Aprendizado Profundo

Discussão: Por que tratar linguagem natural é importante? Por que gerar conteúdo é útil?

Por que tratar linguagem natural é importante?

Desbloqueio dos dados não estruturados das organizações: 80% a 90% de todos os dados do mundo são não estruturados (texto, imagens, vídeo, som)

Linguagem Humana como a Interface Definitiva com Máquinas

Tarefas automatizadas de classificação, clusterização etc.

Aplicações: search engines, sentiment analysis, classificação automática de notícias, emails, artigos, reclamações, bots, reconhecimento de voz, tradução automática etc.

Por que gerar conteúdo é útil?

Ganhos de produtividade e aceleração da criação de “rascunhos”

Personalização e Adaptação Massiva em Tempo Real

Síntese de Conhecimento e Multimodalidade (RAG e Mídias Mistas)

Pré-Processamento do Corpo de Texto no PLN Clássico

Tokenização por Palavras

O que é: Divisão do texto livre em palavras completas delimitadas por espaços e pontuações.

Exemplo: 'corro' e 'corremos' geram 2 tokens separados no vocabulário.

Remoção de Stopwords

O que é: Filtragem de palavras de alta frequência e baixo valor informativo (artigos, preposições).

Exemplo: Remoção de 'o', 'a', 'de', 'em', 'que' antes da vetorização.

Stemming (Radicalização)

O que é: Redução morfológica bruta que corta o sufixo para extrair o radical (stem).

Exemplo: 'correndo', 'corredor', 'correu' -> 'corr' (pode gerar radicais inválidos). Algoritmos baseados em regras rígidas (ex: Porter Stemmer).

Lemmatização

O que é: Redução da palavra à sua forma de dicionário (lema) com análise gramatical.

Exemplo: 'fui', 'fomos', 'serei' -> lema 'ir'; 'melhores' -> lema 'bom'. Requer dicionários e análise de classe gramatical (POS tagging).

Acesse: Aula_01_classic_NLP.ipynb

Representação Vetorial Esparsa: Bag-of-Words e TF-IDF

Bag-of-Words (BoW) & N-Grams

Mecanismo: Cria um vocabulário de todas as palavras únicas do corpus e conta a frequência em cada documento.

Vetores Esparsos: Cada documento vira um vetor do tamanho do vocabulário, preenchido majoritariamente por zeros.

N-Grams: Agrupa N palavras consecutivas (unigramas, bigramas, trigramas) para tentar capturar contexto local.

Gargalos Severos: Ignora a ordem do texto, não entende sinônimos e sofre com a explosão de dimensionalidade.

d1 Human machine interface for ABC computer application.
d2 A survey of user opinion of computer system response time.
d3 The EPS user interface management system.
d4 System and human system engineering testing in EPS.
d5 Relation to user perceived response time to error measurement.
d6 The generation of random, binary, ordered trees.
d7 The intersection graph of paths in trees.
d8 Graph minors IV: Widths of trees and well-quasi-ordering.
d9 Graph minors: A survey.

terms in at least two documents

	tf(i,j)	1 system	2 user	3 graph	4 trees	5 response	6 EPS	7 nterface	8 human	9 survey	10 computer	11 minors	12 time
1	d1	0	0	0	0	0	0	1	1	0	1	0	0
2	d2	1	1	0	0	1	0	0	0	1	1	0	1
3	d3	1	1	0	0	0	1	1	0	0	0	0	0
4	d4	2	0	0	0	0	1	0	1	0	0	0	0
5	d5	0	1	0	0	1	0	0	0	0	0	0	1
6	d6	0	0	0	1	0	0	0	0	0	0	0	0
7	d7	0	0	1	1	0	0	0	0	0	0	0	0
8	d8	0	0	1	1	0	0	0	0	0	0	1	0
9	d9	0	0	1	0	0	0	0	0	1	0	1	0
	df(j)	3	3	3	3	2	2	2	2	2	2	2	2
	idf(j)	1,10	1,10	1,10	1,10	1,50	1,50	1,50	1,50	1,50	1,50	1,50	1,50
inverted index		d2	d2	d7	d6	d2	d3	d1	d1	d2	d1	d8	d2
		d3	d3	d8	d7	d5	d4	d3	d4	d9	d2	d9	d5
		d4	d5	d9	d8								

useful for boolean searches

TF-IDF (Ponderação de Relevância)

Term Frequency (TF): Mede a frequência relativa da palavra no documento específico.

Inverse Document Frequency (IDF): Penaliza palavras que aparecem em quase todos os documentos do corpus.

Fórmula de Relevância: TF-IDF = TF × log(N / DF). Destaca palavras raras e altamente informativas.

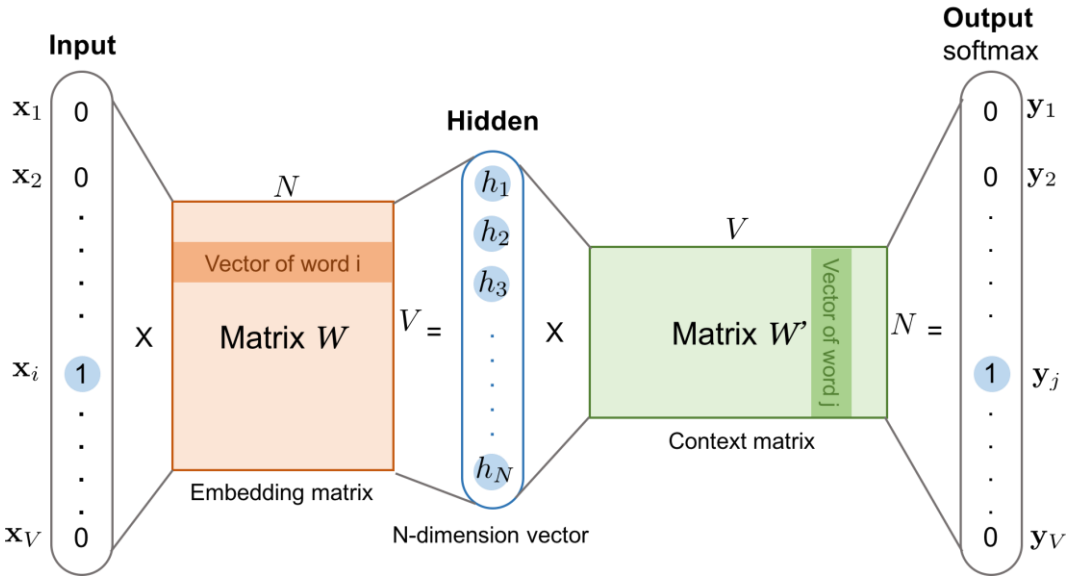
Aplicações Clássicas: Motores de busca lexicais (Lucene, BM25), classificação de documentos e filtragem de conteúdo.

$$\mathrm{TF_IDF}(t,d,D) = \mathrm{TF}(t,d)\ \mathrm{IDF}(t,D) = \frac{f(t,d)}{\sum_{t' \in d} f(t',d)} \log \frac{N}{n_t}$$

tf*idf(j)

1 system	2 user	3 graph	4 trees	5 respons	6 EPS	7 interface	8 human	9 survey	10 comput	11 minors	12 time
0,00	0,00	0,00	0,00	0,00	0,00	1,50	1,50	0,00	1,50	0,00	0,00
1,10	1,10	0,00	0,00	1,50	0,00	0,00	0,00	1,50	1,50	0,00	1,50
1,10	1,10	0,00	0,00	0,00	1,50	1,50	0,00	0,00	0,00	0,00	0,00
2,20	0,00	0,00	0,00	0,00	1,50	0,00	1,50	0,00	0,00	0,00	0,00
0,00	1,10	0,00	0,00	1,50	0,00	0,00	0,00	0,00	0,00	0,00	1,50
0,00	0,00	0,00	1,10	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
0,00	0,00	1,10	1,10	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
0,00	0,00	1,10	1,10	0,00	0,00	0,00	0,00	0,00	0,00	1,50	0,00
0,00	0,00	1,10	0,00	0,00	0,00	0,00	0,00	1,50	0,00	1,50	0,00

Word Embedding



Acesse: https://developers.google.com/machine-learning/crash-course/embeddings

MÓDULO 1: PANORAMA GERAL DA IA

Os Dados Corporativos Constituem o Principal Ativo Diferenciador das Aplicações

1. Tipologia de Dados

Estruturados: Bancos relacionais, planilhas e métricas tabulares.

Semiestruturados: Arquivos JSON, logs e feeds de sensores IoT.

Não Estruturados: Documentos PDF, e-mails, imagens, áudio e código (80%+ dos dados da empresa).

2. Origem e Propriedade

First-party Data: Dados próprios coletados diretamente nas operações (maior valor estratégico).

Second-party Data: Dados compartilhados por parceiros ou fornecedores.

Third-party Data: Fontes públicas e marketplaces externos de dados.

3. Valor Estratégico

Modelos Comerciais São Commodities: O diferencial não é o modelo base, mas os dados corporativos que o alimentam.

Fundamentação (Grounding): Uso de dados próprios para evitar alucinações e trazer respostas precisas.

Governança e Privacidade: Garantia de segurança no tratamento de dados sensíveis.

MÓDULO 2

Modelos de Fundação e Arquitetura Transformer

Entendendo os blocos construtivos: Encoders, Decoders e Mecanismos de Auto-Atenção.

Modelos de Fundação Servem como Base Reutilizável para Diversos Domínios

Large Language Models (LLMs)

Definição: Sistemas de IA baseados em redes neurais profundas treinados para processar, entender e gerar linguagem humana.

Escala de Treinamento: Treinados em terabytes a petabytes de texto cobrindo múltiplos idiomas e linguagens de programação.

Capacidade Emergente: Habilidade de realizar raciocínios complexos, tradução e resumos sem treinamento específico prévio.

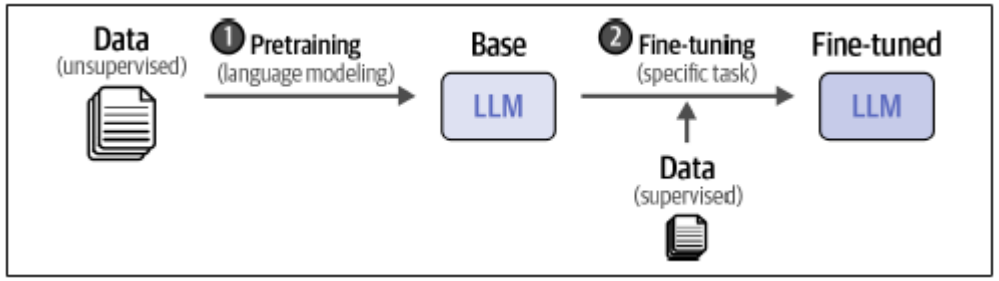
- CLIP / Stable Diffusion (Modelo de Fundação, mas NÃO um LLM)
- Llama 2 ou GPT-4 (Modelo de Fundação E LLM)
- Code Llama e BioBERT (Modelos Especializados)
- E o ChatGPT?

Modelos de Fundação (Foundation Models)

Conceito Central: Modelos de grande escala treinados em dados abrangentes não rotulados que servem de base para tarefas especializadas.

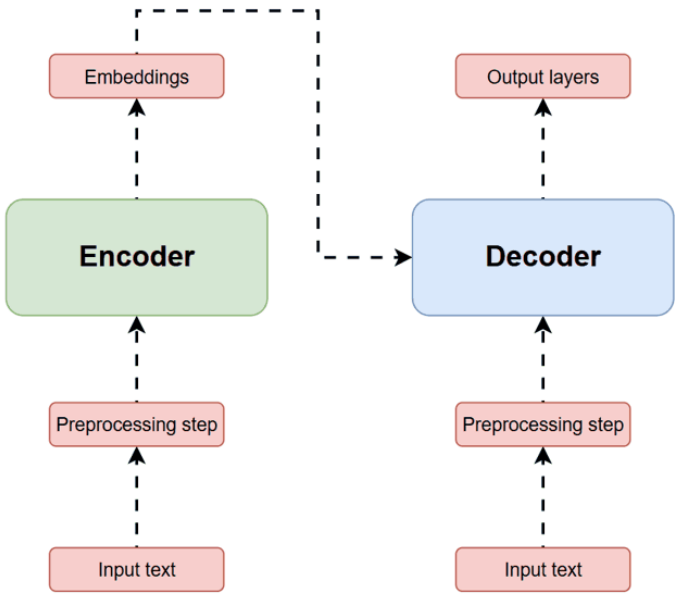
Reutilização Inteligente: Elimina a necessidade de criar e treinar modelos do zero para cada novo problema da empresa.

Suporte Multimodal: Expansão para além do texto, englobando visão computacional, áudio e estruturas biomédicas.



MÓDULO 2: MODELOS E ARQUITETURA

O Mecanismo de Auto-Atenção Permite Processar Sequências Massivas em Paralelo



Componentes Chave da Arquitetura

Self-Attention (Auto-Atenção): Calcula a relevância relativa de cada palavra em relação a todas as outras no mesmo texto.

Multi-Head Attention: Aplica múltiplos mecanismos de atenção em paralelo, capturando diferentes relações semânticas e sintáticas.

Positional Encoding: Injeta a informação da ordem das palavras no vetor de entrada, já que não há recorrência.

Paralelização Massiva: Permite utilizar clusters de GPUs eficientemente durante o treinamento.



Figure 1. A Transformer-based application that translates from English to French.

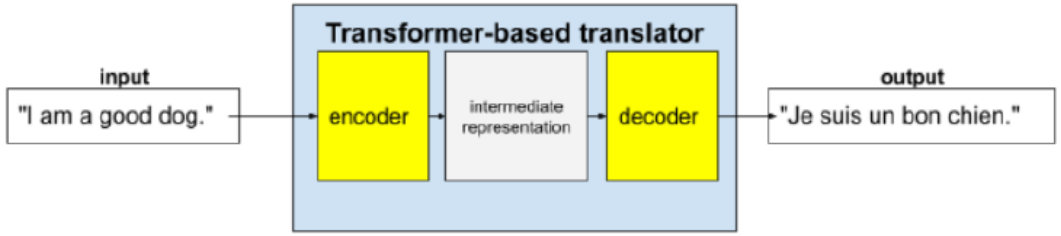


Figure 2. A full Transformer contains both an encoder and a decoder.

MÓDULO 2: MODELOS E ARQUITETURA

Modelos Encoder, Decoder e Encoder-Decoder Atendem a Objetivos Distintos

Tipo de Modelo	Exemplos Típicos	Foco do Mecanismo	Principais Aplicações
Encoder-Only (Representação)	BERT, RoBERTa	Atenção bidirecional em todo o contexto de entrada.	Busca semântica, classificação de texto, análise de sentimento e NER.
Decoder-Only (Generativo)	Família GPT, Llama, Mistral	Atenção causal (autoregressiva, prevê o próximo token).	Chatbots, geração de artigos, escrita de código, resumos e agentes.
Encoder-Decoder (Transformação)	T5, BART, Flan-T5	Encoder processa entrada; Decoder gera a sequência de saída.	Tradução automática, sumarização condicionada e transformação texto-para-texto.

Acesse: Aula_01_LLM_Transformers_Tasks.ipynb

O Ecossistema Comercial e Open-Source Oferece Diferentes Opções de Adoção

Família GPT (OpenAI)

Modelos comerciais de alta capacidade (GPT-4o), pioneiros em instrução e raciocínio multimodal.

BERT (Google)

Modelo bidirecional focado na compreensão profunda e criação de embeddings para busca semântica.

Família Llama (Meta)

Modelos open-source líderes de mercado, permitindo hospedagem local e customização total.

Modelos Especializados

Modelos focados em nichos específicos, como conversão de linguagem natural para SQL (Snowflake Copilot).

SIZING UP THE CONTENDERS

As the software industry steps up research and development into LLMs, several prominent offerings have emerged in this highly competitive sector:

- **OpenAI's GPT** family is based on the GPT series of models. These LLMs are renowned for their impressive language-generation capabilities and capability to perform well across various language tasks, including search, text generation, reasoning, and multimedia content delivery.
- **Bidirectional Encoder Representations from Transformers (BERT),** developed by Google, employs a masked language model to learn contextual representations, enabling it to better comprehend the meaning of sentences. This model powers Google Bard's conversational AI chat service.
- **Llama** (Large Language Model Meta AI) is a family of LLMs introduced by Meta that excels at language translation, text generation, and question-answering. Llama 2 is an open-source model that is available for research and development purposes.
- **Code Llama,** also developed by Meta AI, is a language model tailored to understand and generate code snippets and programming instructions. It has been trained to assist in coding tasks, code completion, and suggesting efficient coding techniques.
- **Snowflake Copilot,** an LLM fine-tuned by Snowflake, generates SQL from natural language and refines queries through conversation, improving user productivity.
- **XLNet,** developed by Carnegie Mellon University and Google, focuses on generating high-quality text in multiple languages, making it useful for language translation and content creation.

MÓDULO 3

Operação, Tokenização e Espaço Vetorial

Como o texto é convertido em números, representado em vetores e recuperado via RAG.

MÓDULO 3: OPERAÇÃO E VETORES

Prompt, Completion, Inferência e Janela de Contexto Definem a Dinâmica Operacional

Prompt

Definição: A instrução, pergunta ou contexto inicial fornecido pelo usuário em linguagem natural.

Completion

Definição: A resposta de saída gerada pelo modelo autoregressivo em reação ao prompt.

Inferência

Definição: O processo computacional de executar o modelo treinado para gerar conclusões a partir dos prompts.

Janela de Contexto

Definição: O limite máximo de tokens que o modelo consegue processar simultaneamente (entrada + saída).

MÓDULO 3: OPERAÇÃO E VETORES

A Tokenização Converte Texto Livre em Unidades Numéricas Processáveis

O Processo de Tokenização

Unidade Básica (Token): Pedaço de texto processado pela rede neural (pode ser palavra, subpalavra ou caractere).

Média de Conversão: Em inglês, 1 token ≈ 0,75 palavras (ou ~4 caracteres). Em português, a taxa varia devido aos acentos.

Tokenizadores Populares: Algoritmos como Byte-Pair Encoding (BPE) e WordPiece fracionam termos raros em subpalavras conhecidas.

Geração Autoregressiva Passo a Passo

1. Entrada de Texto: O usuário envia o prompt que é convertido em Token IDs.

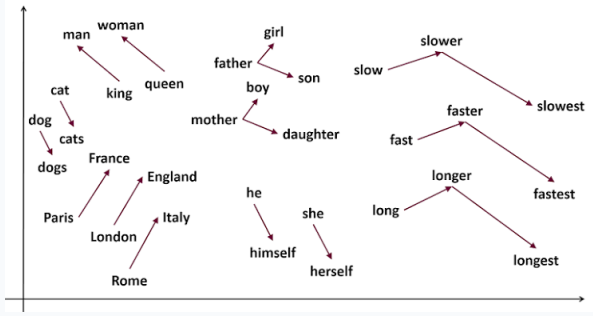
2. Predição de Probabilidade: O LLM calcula a distribuição de probabilidade para o próximo token no vocabulário.

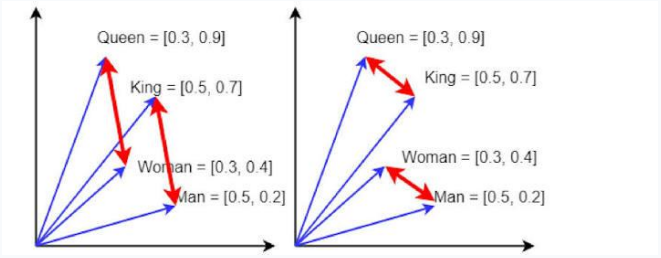
3. Anexação ao Contexto: O token escolhido é anexado à sequência de entrada para prever o próximo token.

4. Critério de Parada: O processo se repete até atingir o limite da janela de contexto ou o token de fim de sequência (EOS).

MÓDULO 3: OPERAÇÃO E VETORES

Embeddings Mapeiam Significados Semânticos em Espaços Vetoriais de Alta Dimensão





$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sqrt{\sum_{i=1}^{n} B_i^2}}$$

Conceito e Similaridade Semântica

Vetor de Alta Dimensão: Representação numéricas densas (ex: 768 a 3072 dimensões) que capturam nuances do significado.

Proximidade Semântica: Conceitos parecidos ficam agrupados próximos no espaço vetorial (ex: 'rei' - 'homem' + 'mulher' ≈ 'rainha').

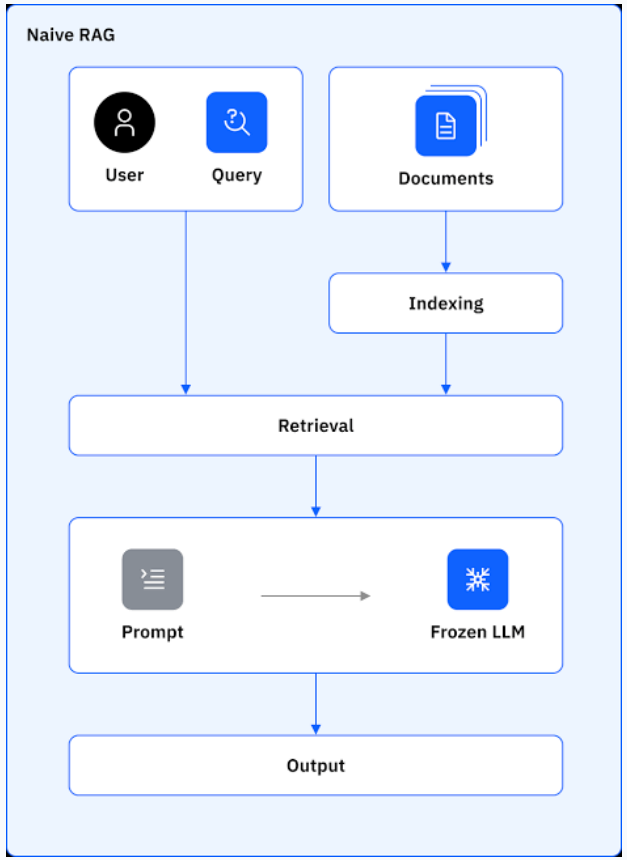
Cálculo de Similaridade: Uso da similaridade de cosseno ou distância euclidiana para comparar trechos de texto.

Bancos de Dados Vetoriais: Sistemas como Pinecone, Chroma e Qdrant otimizados para busca por similaridade em milissegundos.

MÓDULO 3: OPERAÇÃO E VETORES

O RAG Fundamenta Respostas em Bases Corporativas sem Reciclagem de Pesos

Retrieval-Augmented Generation



A Arquitetura RAG

1. Pergunta do Usuário: O prompt do usuário é convertido em embedding vetorial.

2. Busca Vetorial: O banco de dados recupera os trechos de documentos corporativos mais semelhantes.

3. Injeção no Prompt (Grounding): Os trechos recuperados são anexados ao prompt como contexto de apoio.

4. Geração Fundamentada: O LLM responde baseando-se estritamente nos dados reais fornecidos, eliminando alucinações.

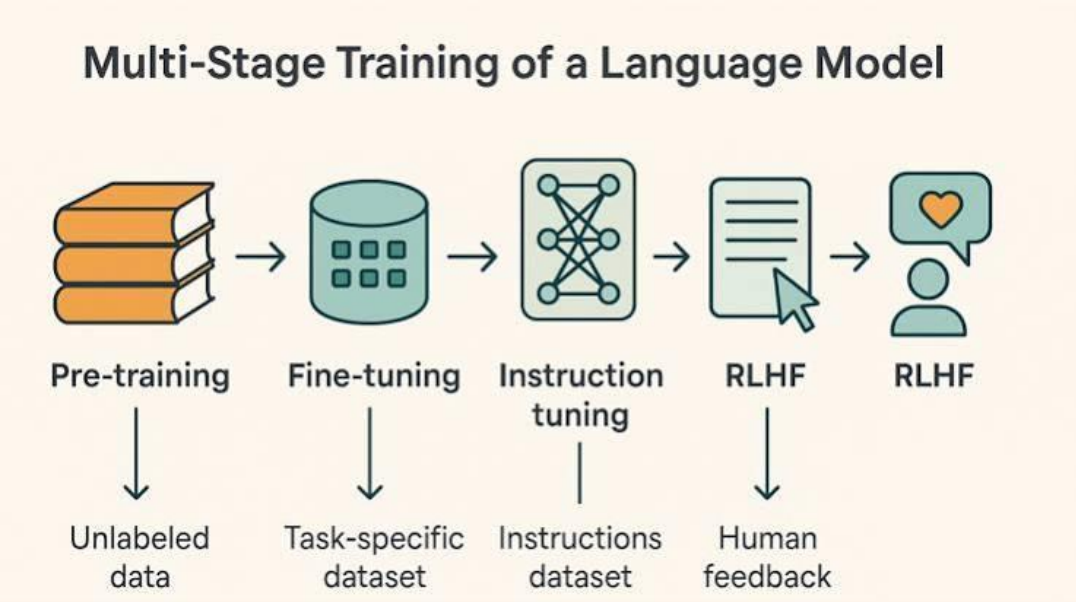
MÓDULO 4

Ciclo de Vida, Treinamento e Adaptação

Das etapas de Pré-Treinamento ao Fine-Tuning Supervisionado, RLHF e Engenharia de Prompt.

MÓDULO 4: TREINAMENTO E ADAPTAÇÃO

O Treinamento em Três Etapas Transforma Modelos Base em Assistentes Alinhados



Visão Geral do Ciclo de Treinamento

Etapa 1: Pré-Treinamento (Pretraining): Modelagem de linguagem auto-supervisionada em grande escala em texto não rotulado.

Etapa 2: Fine-Tuning Supervisionado (SFT): Treinamento em pares selecionados de [Instrução, Resposta] para seguir comandos.

Etapa 3: Alinhamento de Preferência (RLHF/DPO): Ajuste fino com base no feedback humano para garantir utilidade, segurança e evitar viés.

MÓDULO 4: TREINAMENTO E ADAPTAÇÃO

Engenharia de Prompt e In-Context Learning Permitem Adaptação Sem Treinamento

Técnicas de Prompting e Aprendizado no Contexto (In-Context Learning)

Zero-Shot Prompting: Fornece a instrução direta sem nenhum exemplo de demonstração. Funciona bem para tarefas genéricas em modelos avançados.

Few-Shot Prompting: Inclui de 2 a 5 exemplos de pares de [Entrada -> Saída] diretamente no prompt para guiar a estrutura da resposta desejada.

Chain-of-Thought (CoT): Instrui o modelo a 'raciocinar passo a passo' antes de responder, aumentando drasticamente a precisão em tarefas de lógica e matemática.

System Prompts e Personas: Define regras de conduta, estilo e limites de atuação do assistente virtual de forma persistente.

Leituras Recomendadas

Livros-Texto

1. **Generative AI and LLMs for Dummies:** Wiley / IBM. Capítulos 1 (Exploring Generative AI and LLM Concepts) e 2 (Understanding Data and Language Models).
2. **Hands-On Large Language Models:** Alammar, Jay; Grootendorst, Maarten (2024). O'Reilly Media. Capítulo 1 (The Language AI Landscape).