MODELOS DE LINGUAGEM E GENERATIVOS

Avaliação de Modelos (Métricas) & Prática de Pipelines HuggingFace

Por Que Avaliar LLMs? O Desafio da Geração de Linguagem Aberta

O Desafio da Subjetividade

Em problemas de classificação clássica, acurácia e F1 são métricas diretas e determinísticas.

Na geração de texto por LLMs, uma resposta pode ser expressa de dezenas de formas válidas e gramaticalmente corretas. Avaliar fluência, coerência, pertinência e factualidade exige métricas especializadas.

Casos de Uso Críticos

1. Comparação de Modelos:
Determinar qual arquitetura ou checkpoint (Base vs. Fine-Tuned) é superior para a tarefa.

2. Monitoramento de Treino:
Acompanhar a evolução das épocas e prevenir overfitting ou regressão.

3. Otimização de Parâmetros:
Ajustar temperatura, top_p, prompt templates e estratégias de amostragem.

O Padrão Ouro vs. Automação

Avaliação Humana:
É o padrão ouro absoluto, capaz de captar sutilezas, factualidade e nuance cultural.

Gargalo de Escala:
Extremamente lenta, cara e não escalável para inferências contínuas em produção.

Necessidade de Métricas:
Métricas automáticas oferecem um proxy rápido, reproduzível e de baixo custo computacional.

Acesse os notebooks da Aula_06

ROUGE: Avaliação de Resumos por Sobreposição de Conteúdo

Conceito e Variantes do ROUGE (Lin, 2004)

• Recall-Oriented Understudy for Gisting Evaluation:
Projetado especificamente para avaliar resumos, medindo o quanto do conteúdo do texto de referência humano foi capturado pelo modelo gerador.

• ROUGE-N (N-gramas):
ROUGE-1 avalia unigramas (palavras isoladas); ROUGE-2 avalia bigramas consecutivos. Quanto maior N, mais rigorosa é a ordem das palavras.

• ROUGE-L (Longest Common Subsequence):
Avalia a maior subsequência comum entre o texto gerado e a referência. Não exige contiguidade estrita, apenas a manutenção da ordem relativa das palavras.

• ROUGE-S (Skip-Bigram):
Avalia pares de palavras permitindo termos intermediários (skips).

Fórmulas & Exemplo Numérico (Notebook)

Candidato (C): 'The quick brown dog jumps on the log' (8 palavras)
Referência (R): 'The quick brown fox jumps over the lazy dog' (9 palavras)
Sobreposição: 6 palavras comuns {The, quick, brown, dog, jumps, the}

• Precision: m / wc = 6 / 8 = 0.75 (75% das palavras geradas são relevantes)
• Recall: m / wr = 6 / 9 = 0.67 (67% das palavras de referência foram cobertas)
• F1-Score: 2 * (P * R) / (P + R) = 0.71 (Média harmônica balanceada)

```
# Execução em Python com biblioteca 'evaluate':
from evaluate import load
rouge = load('rouge')
results = rouge.compute(predictions=pred, references=ref)
# Retorna: {'rouge1': 0.67, 'rouge2': 0.46, 'rougeL': 0.62}
```

BLEU: A Métrica Clássica da Tradução Automática e Brevity Penalty

Fundamentos do BLEU (Papineni et al., 2002)

• Bilingual Evaluation Understudy:
Métrica criada pela IBM para avaliar sistemas de tradução automática baseada na precisão modificada de n-gramas.

• Foco Estrito em Precisão:
Diferente do ROUGE (que prioriza o Recall/cobertura), o BLEU avalia a fração de n-gramas gerados pelo modelo que estão presentes nas referências humanas.

• A Penalidade de Brevidade (Brevity Penalty - BP):
Modelos poderiam trapacear gerando apenas uma única palavra muito segura (ex: 'The'). O fator BP penaliza severamente traduções menores que a referência:
BP = 1 se c > r, senão exp(1 - r/c)

Fórmula Matemática & O Gargalo da Rigidez

Equação Oficial do BLEU:
BLEU = BP * exp(sum_{n=1}^N w_n * log(P_n))
Onde w_n = 1/N (média geométrica ponderada das precisões de n-gramas, tipicamente N=4).

O Problema Crítico de Multiplicação por Zero:
Se o modelo acertar 1-gramas e 2-gramas, mas errar todos os 4-gramas (P4 = 0), o log(P4) estoura e o BLEU global zera completamente!

No exemplo da Aula 06:
Predição: 'O cão saiu em disparada pela rua.'
Referência: 'Um cão correu rápido pela rua.'
Resultado: BLEU = 0.00 (apesar do sentido perfeitamente equivalente).

METEOR: Alinhamento Linguístico Flexível com Lematização e Sinônimos

Superando as Limitações do BLEU

• Metric for Evaluation of Translation with Explicit Ordering (Lavie & Agarwal):
Criada para resolver a rigidez do BLEU, introduzindo alinhamento semântico e morfológico profundo entre as sentenças.

• Quatro Níveis de Correspondência Sucessiva:
1. Exact Match: Casamento idêntico de palavras.
2. Stem Match: Casamento morfológico via radical (ex: 'correr' e 'correndo').
3. Synonym Match: Consulta de sinônimos via base WordNet.
4. Paraphrase Match: Mapeamento de expressões equivalentes.

• Maior Correlação com Julgamentos Humanos:
O METEOR reflete a avaliação de revisores humanos com muito mais precisão do que o BLEU em tarefas abertas.

Média Harmônica Ponderada & Penalização de Fragmentação

Fórmula do F_mean (Peso maior para Recall):
F_mean = (10 * Precision * Recall) / (Recall + 9 * Precision)
O METEOR valoriza a cobertura de ideias (Recall) muito mais do que a precisão pura.

Penalização de Fragmentação (Penalty):
Penalty = 0.5 * (Chunks / Matches)^3
Score Final = F_mean * (1 - Penalty)

Se as palavras acertadas estiverem fora de ordem ou espalhadas em múltiplos blocos desconexos ('chunks'), a penalização reduz a nota final, premiando a fluência da frase.

```
# Resultado no Notebook Aula 06:
meteor = evaluate.load('meteor')
# 'O cão saiu em disparada...' -> METEOR = 0.44
# Supera o BLEU (0.00) por reconhecer sinônimos e stems.
```

BERTScore: Avaliação Semântica no Espaço de Embeddings Contextuais

A Revolução do BERTScore (Zhang et al., 2019)

• Superando a Sobreposição Lexical:
ROUGE e BLEU exigem que as mesmas palavras literais apareçam no texto. BERTScore utiliza modelos de linguagem pré-treinados (como BERT ou RoBERTa) para avaliar no espaço latente.

• Similaridade de Cosseno Token-a-Token:
Cada token da predição e cada token da referência é convertido em um vetor contextual denso. Em seguida, calcula-se o produto escalar / cosseno entre todos os pares.

• Alinhamento Ótimo (Greedy Matching):
Cada token da predição é pareado com o token mais semelhante da referência (e vice-versa), gerando Precision, Recall e F1-Score semânticos.

Vantagens e Desafios Computacionais

Vantagens Robustas:
• Robusto a Paráfrases: 'Um cão correu rápido' vs. 'O cachorro saiu em disparada' recebem similaridade altíssima (~0.98).
• Sensível ao Contexto: O mesmo termo em contextos diferentes recebe vetores distintos, capturando polissemia.
• Altíssima Correlação com Avaliação Humana.

Desvantagens e Custos:
• Custo Computacional: Requer rodar uma rede neural Transformer para cada par de frases avaliado (mais lento que contagem de n-gramas).
• Dependência do Modelo: O resultado pode herdar características e limites do modelo base de embeddings utilizado.

MoverScore & Earth Mover's Distance: Transporte Ótimo de Massa Semântica

O Conceito de Earth Mover's Distance (EMD)

• MoverScore (Zhao et al., 2019):
Utiliza a teoria do Transporte Ótimo (Earth Mover's Distance / Wasserstein Distance) para comparar o texto gerado com a referência humana.

• Metáfora da 'Movimentação de Terra':
Imagine cada palavra como uma quantidade de 'massa' no espaço vetorial. A métrica calcula o custo mínimo de esforço para transportar toda a massa de palavras da Distribuição A (predição) até a Distribuição B (referência).

• Distância Semântica Euclidiana:
O custo de mover uma palavra para outra é dado pela distância euclidiana entre seus embeddings contextuais.

Capacidades Semânticas e Complexidade

Poder de Generalização:
• Não exige correspondência 1-para-1: Permite mapeamento de 'muitos-para-muitos', acomodando frases que usam três palavras para expressar o conceito de uma única palavra de referência.
• Excelente para textos sem sobreposição léxica alguma.

Complexidade Computacional (NP-Hard):
• Resolver o problema de transporte ótimo em escala exige algoritmos de programação linear.
• Para N elementos, há N! permutações teóricas (ex: para 8 palavras, 8! = 40.320 possibilidades).
• MoverScore é restrito a avaliações offline e benchmarks acadêmicos devido ao alto tempo de processamento.

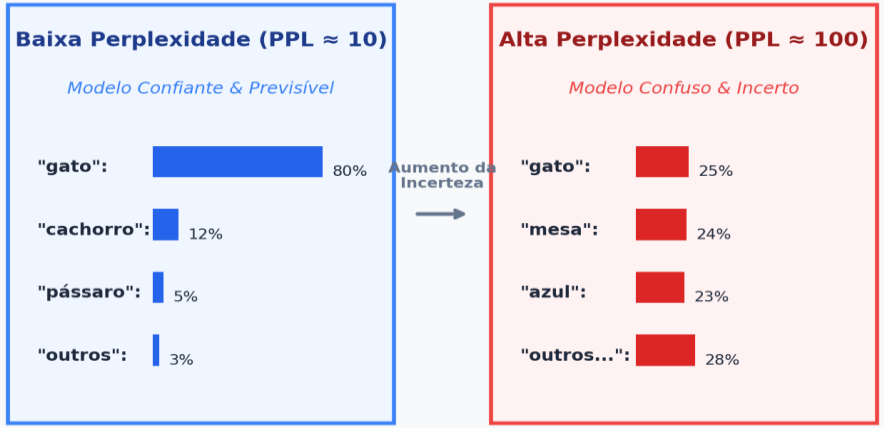
Perplexidade (PPL): Medindo a Incerteza e a Confusão do Modelo

O Que É Perplexidade? (Jelinek et al., 1977)

• Métrica Intrínseca (Sem Gabarito Humano):
Diferente de ROUGE, BLEU e BERTScore, a perplexidade NÃO requer um texto de referência humana. Ela avalia o quão bem o modelo de linguagem prevê um texto de teste.

• Medida de 'Surpresa' ou 'Confusão':
PPL mede o quão surpreso o modelo fica ao ler as frases. Quanto MENOR a perplexidade, mais confiante e bem calibrada está a distribuição de probabilidade.

• Intuição Prática:
• PPL = 10: O modelo está 'em dúvida' entre apenas 10 palavras prováveis a cada passo.
• PPL = 100: O modelo está disperso e altamente confuso.



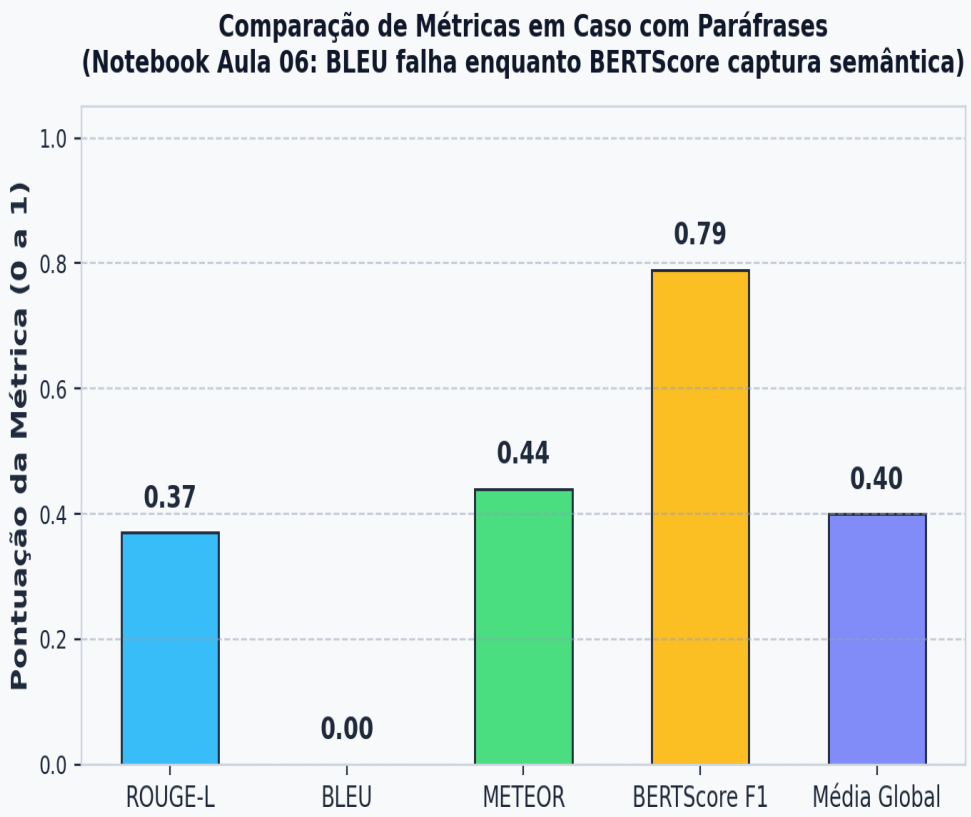
Fórmula e Limitações Cruciais

PPL = exp(- 1/N * sum_{i=1}^N ln P(w_i | w_{<i}))
(Exponencial da Perda Negativa de Log-Verossimilhança - NLL)

Atenção: Modelos só podem ter PPL comparada se usarem o MESMO vocabulário (tokenizer). PPL não mede raciocínio, nem alucinação, nem factualidade!

PARTE 1 • ANÁLISE PRÁTICA

Estudo Comparativo: Casos Onde BLEU Falha e BERTScore Acerta



O Experimento do Notebook (Aula 06)

Parâmetros do Teste no Notebook:

- **Predição: 'O cão saiu em disparada pela rua.'**
- **Referência: 'Um cão correu rápido pela rua.'**

1. BLEU = 0.00: A métrica zerou completamente porque os n-gramas de ordem superior não tiveram correspondência exata de palavras.

2. ROUGE-L = 0.37: Nota baixa devido à penalização da ordem e falta de sobreposição dos unigramas 'saiu em disparada' vs 'correu rápido'.

3. METEOR = 0.44: Pontuação intermediária graças ao alinhamento de sinônimos/lemas do WordNet.

4. BERTScore F1 = 0.79: Capturou com maestria que 'sair em disparada' e 'correr rápido' residem na mesma vizinhança semântica vetorial!

Introdução ao pipeline do HuggingFace

pipeline do HuggingFace

- **Pré-processamento**: o texto é convertido em números (*tokens*) por um **tokenizador**;
- **Modelo**: a rede neural recebe os tokens e produz uma saída numérica;
- **Pós-processamento**: a saída numérica é convertida de volta em algo legível (texto, rótulos, probabilidades).

A função pipeline() da biblioteca transformers **empacota essas três etapas** em um único objeto, que pode ser chamado como se fosse uma função. O uso geral tem sempre a mesma forma:

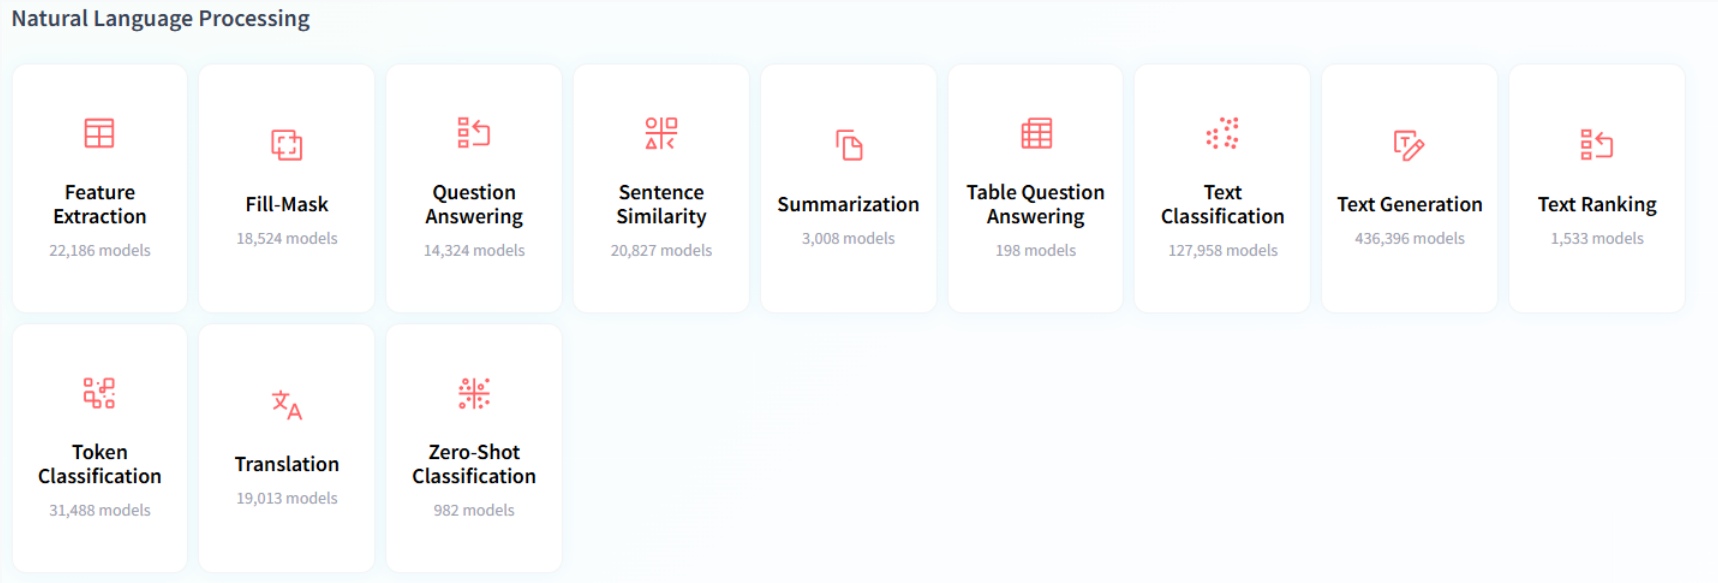
```
from transformers import pipeline

meu_pipeline = pipeline("nome-da-tarefa", model="organizacao/nome-do-modelo")
resultado = meu_pipeline(entrada, **parametros_opcionais)
```

Acesse os notebooks e exercício da Aula_06

PARTE 2 • Prática de Pipelines HuggingFace

Introdução ao pipeline do HuggingFace



#	Tarefa	Biblioteca/Pipeline
1	Chat simples	`text-generation`
2	Chat com contexto	`text-generation`
3	Resumo de texto	`text-generation`
4	Classificação *zero-shot*	`zero-shot-classification`
5	Classificação de textos	`text-classification`
6	Geração de áudio	`text-to-audio`
7	Segmentação de imagens	`image segmentation`
8	Geração de imagens	`text-to-image`

Leituras recomendadas

1. https://huggingface.co/learn LLM Course